

1.

(1)

class	-	-	-	-	+	+	-	-	+	+
	0.08	0.15	0.35	0.44	0.45	0.47	0.55	0.67	0.69	0.73
TP	2									
FP	2									
TN	4									
FN	2									
accuracy	0.6									
precision	0.5									
TPR(recall)	0.5									
FPR	1/3									
F-measure	0.5									

(2)

class	+	+	-	-	+	-	-	-	+	-
	0.01	0.03	0.04	0.05	0.09	0.31	0.38	0.45	0.61	0.68
TP	1									
FP	1									
TN	5									
FN	3									
accuracy	0.6									
precision	0.5									
TPR(recall)	0.25									
FPR	1/6									
F-measure	1/3									

TPR, $M1 > M2$, 分类模型 M1 在这个测试集上表现得更好。

(3)

class	-	-	-	-	+	+	-	-	+	+
	0.08	0.15	0.35	0.44	0.45	0.47	0.55	0.67	0.69	0.73
TP	4									
FP	4									
TN	2									
FN	0									
accuracy	0.6									
precision	0.5									
TPR(recall)	1									
FPR	2/3									
F-measure	2/3									

TPR=1, 阈值为 0.2 时结果更好。

(4)

对于模型 M1,

class	-	-	-	-	+	+	-	-	+	+	
Threshold>=	0.08	0.15	0.35	0.44	0.45	0.47	0.55	0.67	0.69	0.73	1.0
TP	4	4	4	4	4	3	2	2	2	1	0
FP	6	5	4	3	2	2	2	1	0	0	0
TN	0	1	2	3	4	4	4	5	6	6	6
FN	0	0	0	0	0	1	2	2	2	3	4
accuracy	0.4	0.5	0.6	0.7	0.8	0.7	0.6	0.7	0.8	0.7	0.6
precision											
TPR	1	1	1	1	1	0.75	0.5	0.5	0.5	0.25	0
FPR	1	5/6	2/3	0.5	1/3	1/3	1/3	1/6	0	0	0
F-measure											

阈值取 0.45 时最优, 此时 accuracy = 0.8, TPR=1, FPR=1/3.


对于模型 M2,

class	+	+	-	-	+	-	-	-	+	-
Threshold>=	0.01	0.03	0.04	0.05	0.09	0.31	0.38	0.45	0.61	0.68
TP	4	3	2	2	2	1	1	1	1	0
FP	6	6	6	5	4	4	3	2	1	1
TN	0	0	0	1	2	2	3	4	5	5
FN	0	1	2	2	2	3	3	3	3	4
accuracy	0.4	0.3	0.2	0.3	0.4	0.3	0.4	0.5	0.6	0.5
precision										
TPR(recall)	1	0.75	0.5	0.5	0.5	0.25	0.25	0.25	0.25	0
FPR	1	1	1	5/6	2/3	2/3	0.5	1/3	1/6	1/6
F-measure										

阈值取 0.61 时最优, 此时 accuracy = 0.6, TPR = 0.25, FPR = 1/6.

2.

(1)



由图可以看出, 不存在任意一条直线可以将样本正确分类, 所以此训练样本线性不可分。

(2)

使用 Sigmoid 激活函数，给神经元引入了非线性因素，使得神经网络可以任意逼近任何非线性函数，这样神经网络就可以应用到众多的非线性模型中。而如果将 Sigmoid 函数换成线性函数，则隐藏层就失去了意义，每一层输出都是上层输入的线性函数，无论神经网络有多少层，输出都是输入的线性组合。

(3)

神经网络结构：

$x_0 = 1, g(x) = \frac{1}{1+e^{-x}}$, 取样本 1 分析, $\begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$,

由于各连接权重 $\Theta^{(l)}$ 初始化为 0,

$a_1^{(2)} = g(\Theta_{10}^{(1)} x_0 + \Theta_{11}^{(1)} x_1 + \Theta_{12}^{(1)} x_2) = g(0) = \frac{1}{2}$,

$a_2^{(2)} = g(\Theta_{20}^{(1)} x_0 + \Theta_{21}^{(1)} x_1 + \Theta_{22}^{(1)} x_2) = g(0) = \frac{1}{2}$,

$a_1^{(3)} = g(\Theta_{10}^{(2)} a_1^{(2)} + \Theta_{11}^{(2)} a_2^{(2)}) = g(0) = \frac{1}{2}$, 标签为“+”。

由于权重为 0, 则对于各个样本, 所有 $a_j^{(3)} = \frac{1}{2}, (j=1,2,3,4,5)$,

输出解为 $\begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$ 。

Gradient computation: Backpropagation algorithm

Intuition: $\delta_j^{(l)}$ = “error” of node j in layer l .

For each output unit (layer $L = 4$)

$\delta_j^{(4)} = a_j^{(4)} - y_j$ (where $a_j^{(4)} = (h_{\Theta}^{(4)})_j$)

$\delta_j^{(3)} = \frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(3)}} = a_j^{(3)} \delta_i^{(4)}$ (ignoring λ if $\lambda = 0$)

$\delta_j^{(2)} = \frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(2)}} = a_j^{(2)} \delta_i^{(3)}$

$\delta_j^{(1)} = \frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(1)}} = a_j^{(1)} \delta_i^{(2)}$

Backpropagation algorithm

Training set $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$

Set $\Delta_{ij}^{(l)} = 0$ (for all l, i, j).

(use to compute $\frac{\partial}{\partial \Theta_{ij}^{(l)}} J(\Theta)$)

For $i = 1$ to $m \leftarrow (\underline{x^{(i)}}, \underline{y^{(i)}})$

Set $a^{(1)} = x^{(i)}$

Perform forward propagation to compute $a^{(l)}$ for $l = 2, 3, \dots, L$

Using $y^{(i)}$, compute $\delta^{(L)} = a^{(L)} - y^{(i)}$

Compute $\delta^{(L-1)}, \delta^{(L-2)}, \dots, \delta^{(2)}$

$\Delta_{ij}^{(l)} := \Delta_{ij}^{(l)} + a_j^{(l)} \delta_i^{(l+1)}$

$:= \Delta_{ij}^{(l)} + \delta^{(l+1)} (a^{(l)})^T$

$$D_{ij}^{(l)} := \frac{1}{m} \Delta_{ij}^{(l)} + \lambda \Theta_{ij}^{(l)} \text{ if } j \neq 0$$


$$D_{ij}^{(l)} := \frac{1}{m} \Delta_{ij}^{(l)} \text{ if } j = 0$$

$$\frac{\partial}{\partial \Theta_{ij}^{(l)}} J(\Theta) = D_{ij}^{(l)}$$

在前馈算法中，矩阵权重初始化为 0 导致计算的结果都为 ‘+’，分类不正确，神经网络没起到任何作用；在 BP 算法中，权重初始为 0，将导致最终结果都为 0，反向传播也失去了意义。

(4)

设计 RBF 神经网络如图，



激活函数：

$$b(x) = \sum_{i=1}^q w_i p(x, c_i),$$

高斯径向基函数：

$$p(x, c_i) = e^{-\beta_i \|x - c_i\|^2}$$

通常采用两步过程来训练 RBF 网络，第一步：确定神经元中心 c_i ，常用的方式包括随机取样，聚类等；第二步，利用 BP 算法等来确定参数 w_i 和 β_i 。
经过代码测试，取隐藏层数为 10，学习率为 0.5，结果如图：

命令行窗口

输出结果

1.0001										
0.9949										
0.0040										
-0.0460										
0.0549										

参数wi

0.4528	0.2573	-0.2403	0.6879	-0.1175	-0.2976	-0.3193	0.2277	0.6545	0.1640
--------	--------	---------	--------	---------	---------	---------	--------	--------	--------

参数betai

1.7908	1.3807	0.5279	1.5383	1.0207	1.0877	0.9553	1.4465	1.5477	1.1109
--------	--------	--------	--------	--------	--------	--------	--------	--------	--------

参数ci

0.5975	0.1249
0.3353	0.0244
0.2992	0.2902
0.4526	0.3175
0.4226	0.6537
0.3596	0.9569
0.5583	0.9357
0.7425	0.4579
0.4243	0.2405
0.4294	0.7639

fx

激活 Win
转到“设置”以

激活 Wir
转到“设置”

3.

(1)

$$\text{根节点信息熵 } \text{Ent}(\text{root}) = - \sum_{k=1}^2 p_k \log_2 p_k = -(4/10) \log_2 (4/10) - (6/10) \log_2 (6/10) = 0.97$$

以属性 A 划分的信息熵 $\text{Ent}(D^1) = 0.985$, $\text{Ent}(D^2) = 0$;

$$\text{信息熵增益 } \text{GAIN} = \text{Ent}(D) - \sum_{k=1}^2 \frac{|D^k|}{|D|} \text{Ent}(D^k) = 0.28;$$

以属性 B 划分的信息熵 $\text{Ent}(D^1) = 0.81$, $\text{Ent}(D^2) = 0.65$;

$$\text{信息熵增益 } \text{GAIN} = \text{Ent}(D) - \sum_{k=1}^2 \frac{|D^k|}{|D|} \text{Ent}(D^k) = 0.26;$$

以 A 划分的信息熵增益更大，所以选择 A 划分。

(2)

根节点 Gini 系数 $\text{Gini}(\text{root}) = 0.48$;

以属性 A 划分 $\text{Gini}(T) = 0.49$, $\text{Gini}(F) = 0$; Gini 增益为 $0.48 - 0.34 = 0.12$;

以属性 B 划分 $\text{Gini}(T) = 0.38$, $\text{Gini}(F) = 0.28$, Gini 增益为 $0.48 - 0.32 = 0.16$;

以属性 B 划分的信息熵增益更大，所以选择 B 划分。

(3)

根节点的分类误差 $\text{Error}(\text{root}) = 0.4$;

以属性 A 划分 $\text{Error}(T) = 3/7$, $\text{Error}(F) = 0$, Error 增益为 0.1 ;

以属性 B 划分 $\text{Error}(T) = 0.25$, $\text{Error}(F) = 1/6$, Error 增益为 0.2 ;

以属性 B 划分的分类误差增益更大，所以选择 B 划分。

(4)

信息熵增益偏好于属性 A，Gini 增益，分类误差增益更偏好于属性 B。